Vearch --高性能、高可用的分布式向量数据库

孙延好

孙延好
京东后端技术部
架构师

目录

向量数据库概述

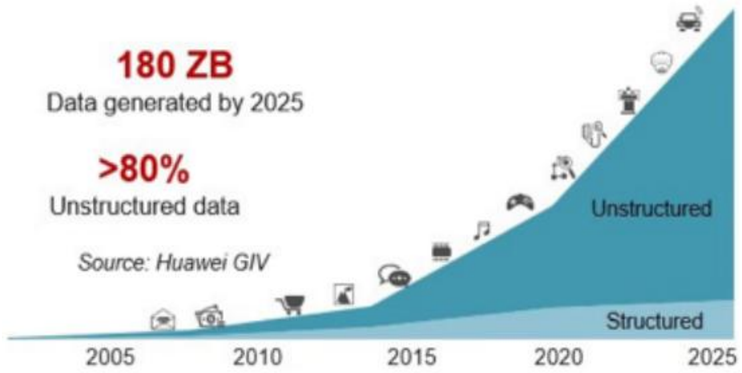

数据发展的趋势

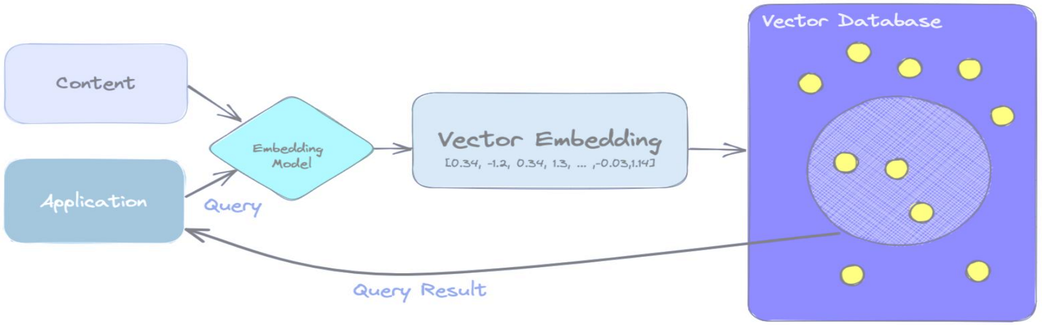

非结构数据的使用情形

- 向量数据库：是面向向量嵌入(vector embedding)而设计数据库系统,通过比较值查找比较相似的向量进行索引，从而进行搜索和分析

向量数据库的发展历程

01	02	03	04	05	06	07
Faiss	Milvus	Vearch	Om-iBASE	TensorDB	Proxima	Zilliz Cloud
2017	2019	2019	2020	2020	2021	2022
2017年3月，Facebook开源支持相似度检索和聚类，多种索引方式，CPU和GPU计算，以及Python和C++调用。其使用场景最常见的为人脸比对，指纹比对，基因比对等。	2019年4月，Milvus 0.1发布，2019年10月，Ziiliz开源了向量数据库开Miivus。Milvus是一款开源的特征向量相似度搜索引擎。Milvus使用方便、实用可靠、易于扩展、稳定高效和搜索迅速。	Vearch v1.0发布。京东研发的一款分布式向量搜索系统，可以用来计算向量相似度或用于机器学习领域，如:图像识别，视频识别或自然语言处理各个领域。Vearch基于Faiss实现，提供了快速的向量检索功能。	Om-iBASE(向量数据库)是基于智能算法提取需存储内容的特征，转变成具有大小定义、特征描述、空间位置的多维数值进行向量化存储的数据库，使内容不仅可被存储，同时可被智能检索与分析。	TensorDB是爱可生公司基于Milvus进行完善增强的企业发行版向量数据库软件。该产品实现了超大规模向量型数据的高效组织，设计了易扩展的索引结构，有效支撑了时变环境下的向量数据快速比对。	2021年10月，阿里巴巴达摩院开源了自研Proxima的向量检索内核。目前，其核心能力广泛应用于阿里巴巴和蚂蚁集团内众多业务，如淘宝搜索和推荐、蚂蚁人脸支付、优酷视频搜索等。2021年12月阿里云正式发布OpenSearch向量检索版。	2022年8月，Ziiliz推出了云端全托管向量数据库服务Zilliz Cloud，进一步赋能企业AI应用，在全球范围内享有广阔的市场前景。

向量数据库的商业价值

Pinecone

Pinecone总部位于纽约，专为OpenAI的GPT-4等大型语言模型(LLMs)提供长期记忆服务。Vector Search专注于通过AI生成的内容表示进行存储和搜索。Pinecone是OpenAI、Cohere等LLM生成商的合作方

- 2019年，Pinecone创始人Edo Liberty创立Hypercube.ai，提供深度学习的多媒体搜索解决方案
- 2021年初，Hypercube.ai正式转化为Pinecone，专注于向量数据库领域研发，融资1000万美金
- 2022年12月起，Pinecone先后上架Google Cloud和AWS， 打开市场。融资2800万美金
- 2023年5月B轮1亿美金

Milvus

Milvus的开发公司Zilliz成立于2017年，全球向量数据库领域的开拓者，以技术为核心，专注于在非结构化数据的分析中挖掘其价值，研发为人工智能服务的向量数据库系统，使更多的企业、组织、个人用更低的成本开发人工智能应用并从中获得便利。

- 2017年，完成天使轮融资，金额高达数千万人民币
- 2018年，完成A轮融资，金额高达1000万美元
- 2019年，Zilliz推出开源向量数据库Milvus
- 2020年，完成B轮融资，金额高达4300万美元
- 2022年，完成B+轮融资，金额高达6000万美元

向量数据库在LLM中的应用

构建阶段

产品文档、知识库、FAQ

文档切分

Text2Vec

存储到向量数据库

应用阶段

如何使用 chatGLM 这个产品？

Text2Vec

按相似性取 Top-k

拼接生成 Prompt

LLM

回复

Vearch定位：海量向量高效存储和检索的一站式解决方案

高性能：千亿规模的向量检索毫秒级响应

高可用：经过多次大促流量洪峰锤炼

高可扩展：支持在线水平扩容或迁移

数据新鲜：数据写入实时可见

属性过滤：结合元数据过滤，查询更快，结果更准

定义数据逻辑视图，支撑功能丰富、高效灵活的查询接口

ID	Scalar-Colum1	Vector-Column1	Vector-Column2
1	1.0	[1.0, 2.0]	[1.01, 2.87,…, 3.09]
2	2.0	[1.1, 2.1]	[1.10, 2.12,…, 3.61]
3	3.0	[1.2, 2.2]	[1.22, 2.52,…, 3.72]
4	4.0	[1.3, 2.3]	[1.34, 2.43,…. 3.34]
5	5.0	[1.5, 2.5]	[1.54, 2.45,…, 3.51]
6	6.0	[1.6, 2.6]	[1.56, 2.46,…, 3.46]
7	7.0	[1.7, 2.7]	[1.27, 2.57,…, 3.76]

- 以Table的形式进行数据组织，支持多Table逻辑隔离不同的业务数据
- 支持标量或者矢量，支持标量索引和向量索引加速检索
- 支持类ES的Restful查询接口，支持Attribute-Filtering和Multi-Vector混合查询
- 支持python sdk，能够更好与AI生态衔接

Vearch定位：构建分布式集群方案，实现高可用、可扩展

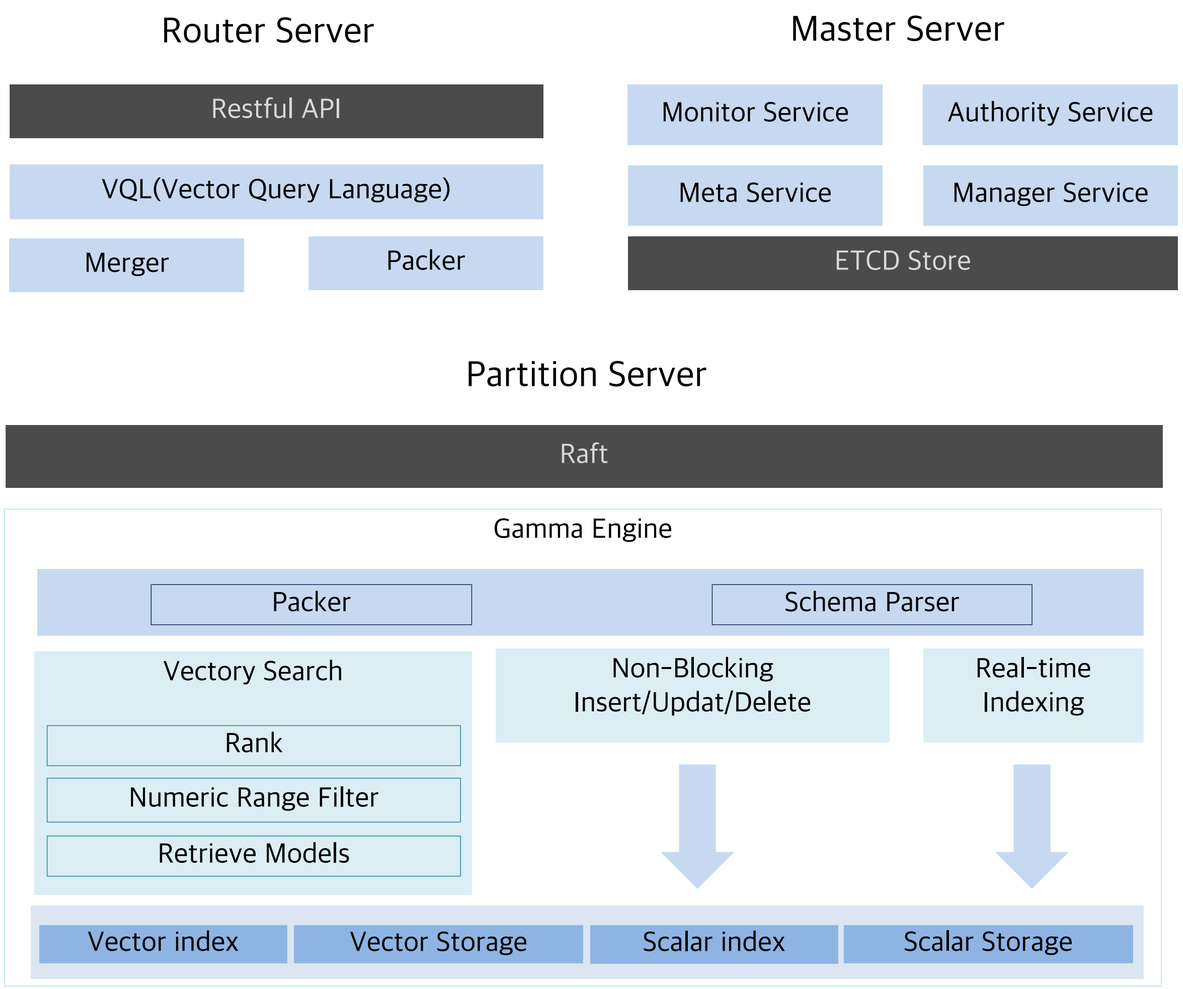

集群化

- 百亿级数据规模支撑

可扩展

- 支持横向在线扩容
- 支持数据在线迁移

高可用

- 基于Raft算法，支持数据多副本可靠存储
- 支持自动故障发现及恢复
- 支持数据及索引的持久化存储

云原生

- 支持一键K8S部署
- 存储与计算分离

Vearch的异构混合架构，实现低成本、高性能

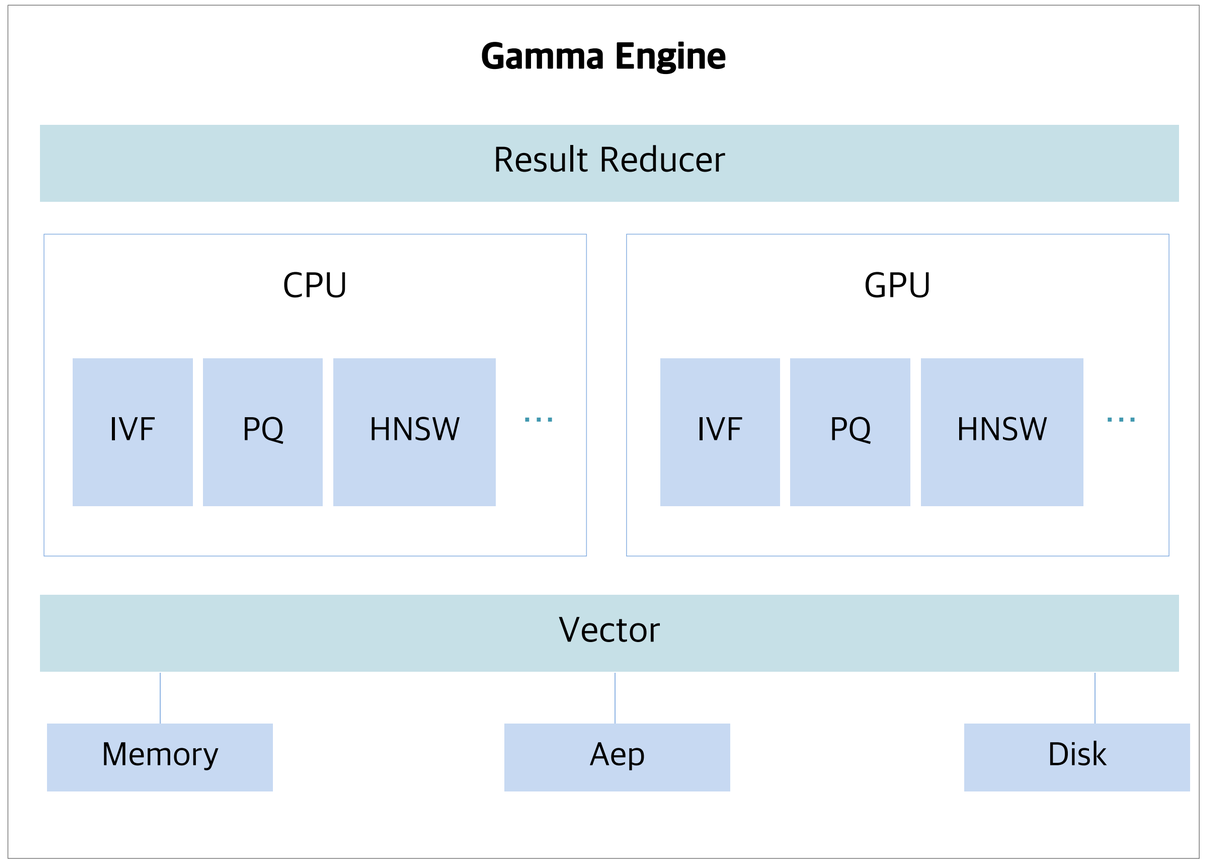

适应不同数据规模的最优召回匹配模型

- IVFPQ速度快，适用于亿级、十亿级数据规模
- HNSW查询精度高，适用于千万级数据规模
- 二进制索引用于处理unit8数据场景

基于GPU和CPU异构平台的优化

- 指令重排，提升cache命中率
- 计算负载精细化调度，充分发挥GPU大数据量处理能力

分层存储体系构建

- 针对不同业务场景使用不同存储来平衡性能和成本消耗
- 支持在线热切换存储，自适应对性能和容量的诉求变更

Vearch支持实时索引，实现数据写入可实时检索技术

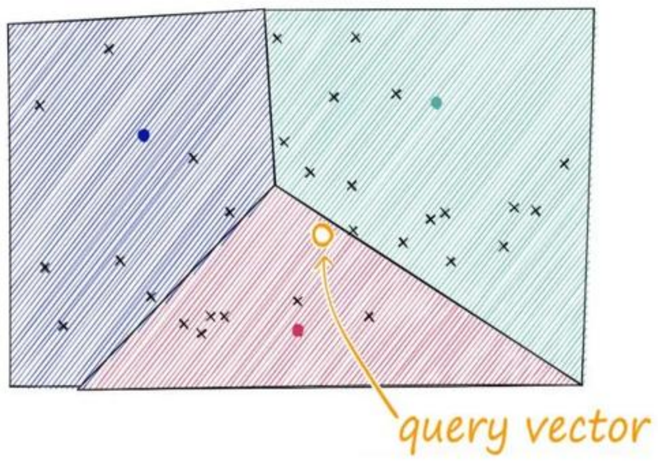

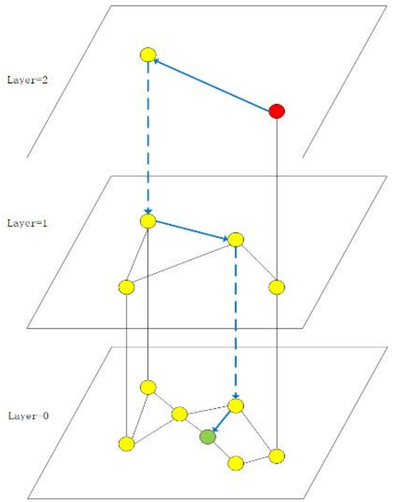

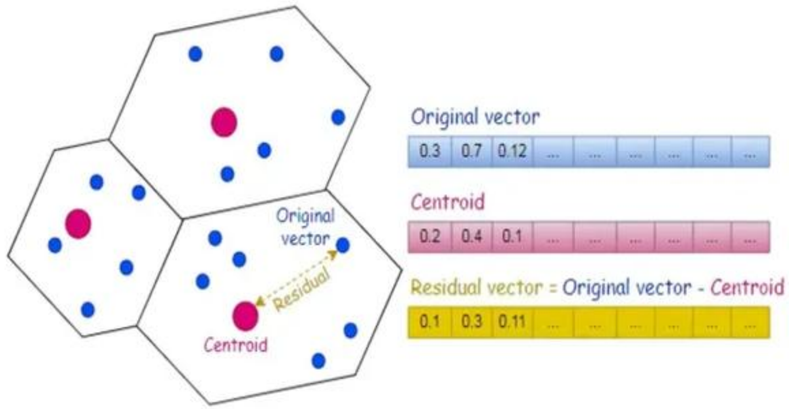

IVF

特点：构建索引快，召回非常高

算法原理：聚类进行分类

关键技术：原子指针、延迟释放

HNSW

特点：检索快、精度高

算法原理：图节点邻接加速检索路径

关键技术：图节点预分配、动态节点扩展

PQ

特点：检索快、内存占用小

算法原理：压缩量化

关键技术：动态索引切换

Vearch 的索引Inplace update和Compaction方案

- Table中的实现

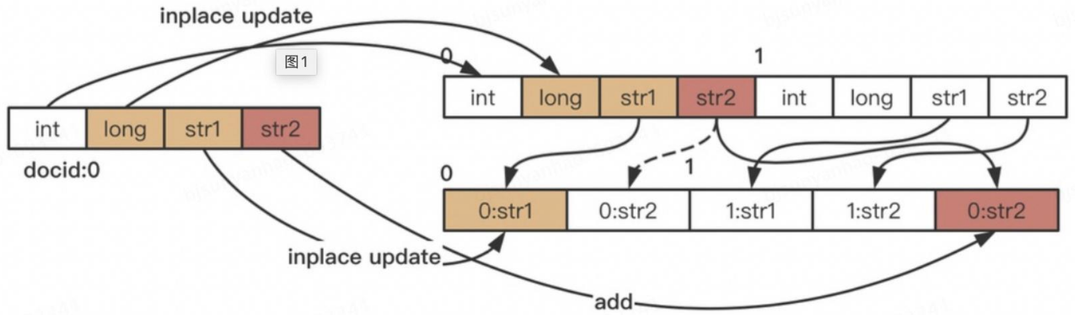

- Raw vector中的实现

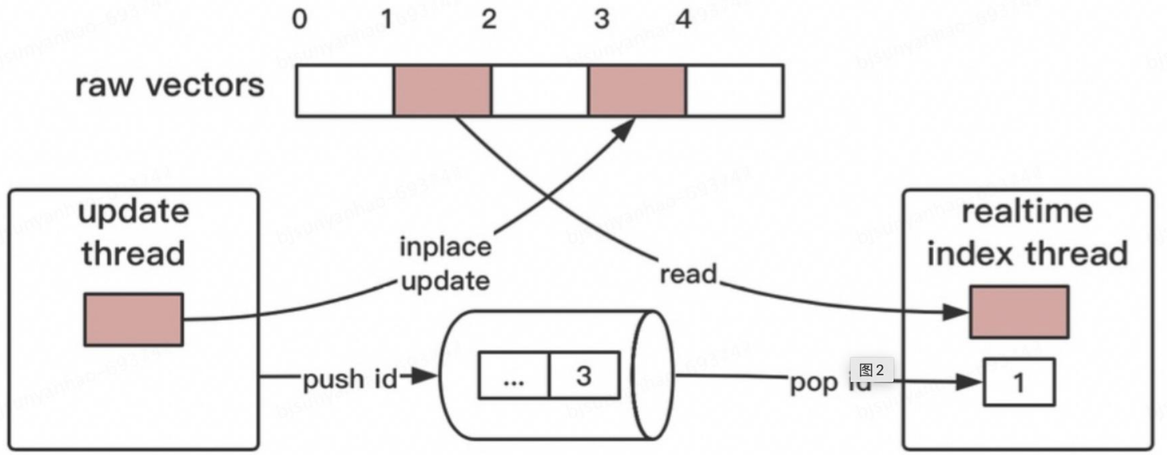

Vearch 的索引Inplace update和Compaction方案

- 倒排索引中的实现

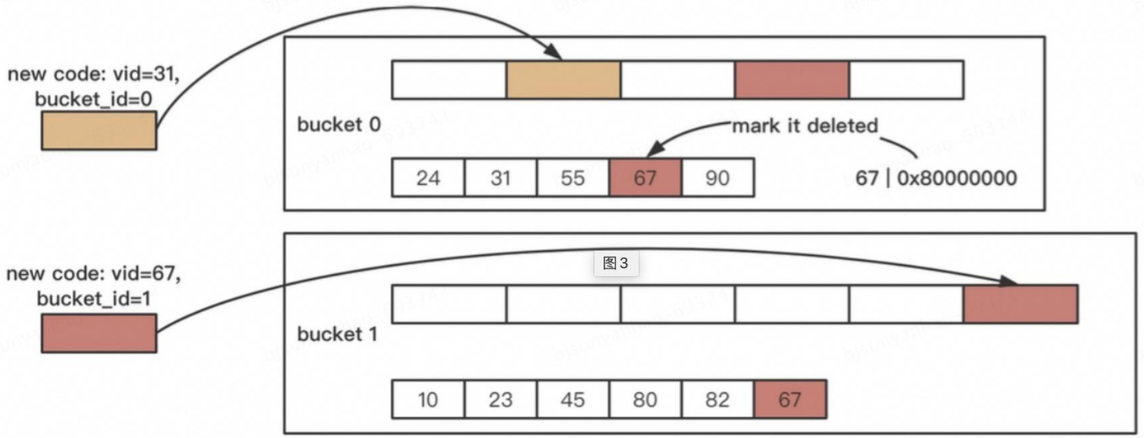

- compaction

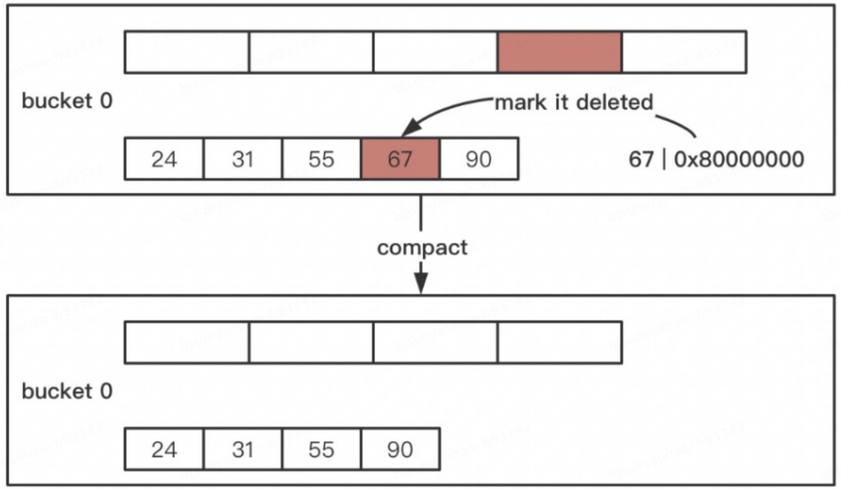

Vearch数据库：在内外部多个领域被广泛应用

向量数据库的一些落地场景

使用企业：100+，总数据量：1000亿+
Star 1.7k，Issues 547

图片场景	重复铺货丨同款推荐丨图片侵权治理丨敏感头像检测丨新品识别丨…
文本场景	智能问答词向量丨用户意图分析丨涅槃词向量丨风控团伙作弊治理丨本地知识库构建丨…
视频场景	视频去重丨人脸识别丨…
推荐	直播种草推荐丨商品推荐丨优惠券推荐丨…

【论文发表：The Design and Implementation of a Real Time Visual Search System on JD E-commerce Platform. In the 19th International ACM Middleware Conference, December 10-14, 2018, Rennes, France.】

THANKS

软件正在重新定义世界

Software Is Redefining The World